2.4B

130U-FinLLM

自用金融语言模型 · 24M Trial 公开展示

把个人金融标准，变成模型行为

我做 130U-FinLLM，是为了把自己的金融研究经验转化为一个能够持续使用、解释和迭代的语言模型系统。它结合本人原创的历史金融观点与人工审核的公开金融文本，围绕一个具体问题展开：**面对一段金融材料，谁在对什么表达判断，依据是什么，哪些条件会改变这个判断。**

项目由两个版本组成：24M Trial 展示从数据、基础训练到任务适配的工程过程；2.4B 是面向个人金融研究的自用模型，以金融语义建模和统一的多任务训练体系为技术主线。公开内容以 Trial 的代码、实验和工程方法为入口。

我选择从训练层面掌握这个系统：亲自定义语料如何进入模型、监督落在哪些位置、不同任务如何共享能力，以及模型输出怎样进入实际研究流程。个人材料在其中提供两种价值：原创观点记录分析习惯，人工裁决沉淀稳定的判读标准。

整个项目以两项设计为核心：**金融语义许可监督**，规定模型应该对什么变化作出响应；**保持训练目标的扩容工程**，保证这些规则经过数据扩增、多任务训练和规模扩展后仍然保持原意。

先用 24M 验证，再把系统扩展到 2.4B

24M 是整个项目的工程起点。较小的模型让我能够完整观察训练过程，快速定位数据、标签、优化和评价之间的关系，并将每一次调整落实到具体样本与计算记录。

这一阶段最有价值的发现，是总体准确率与实际任务能力可能严重脱节。Trial 初版在开发集上全部预测 neutral，准确率仍达到 75.25%，但两个方向类的召回均为零。调整类别曝光和训练预算后，方向识别恢复，同时也增加了中性文本的方向误报。这让我建立起一条贯穿项目的原则：**评价既要看模型学会了什么，也要看它为此增加了哪种错误。**

2.4B 承接的是这套任务协议、错误分析和实验方法。扩展时，词表、模型权重、上下文处理、训练状态与概率校准分别重建，避免把小模型的局部配置直接当作规模化答案。

结构	24M Trial	2.4B 自用版本
总参数	24,255,744	2,397,459,968
Transformer 层数	6	28
隐藏维度	512	2,560
FFN 中间维度	1,664	8,320
每层 Q / KV heads	8 / 4	20 / 4
词表 / 上下文上限	8,192 / 512	65,536 / 4,096

主干采用 dense decoder、GQA、RoPE、RMSNorm 与 SwiGLU，输入 embedding 与输出词表投影共享权重。2.4B 的每层包含 20 个 query heads、4 个 key/value heads，每个 head 的维度为 128。这一结构为金融文本、目标条件与多任务监督提供统一的计算基础。

选择 2.4B，是为了同时容纳更复杂的目标关系与金融表达，并保持参数、状态内存和运行时实现的可控性。项目将容量用于多条件下的语义判读，把语料质量、监督设计和计算效率作为同等重要的工程对象。

四步训练，形成完整闭环

第一步：将材料组织为明确的学习任务

语料按本人原创观点、本人审核的公开文本、通用语言材料和金融原文分类。每条任务明确目标、观点持有人、证据范围和可得时点；原文立场、指标方向和本人判断分别定义。

同一事件的原文、目标查询、问答与编辑归入同一个样本家族。先划分数据，再生成派生视图，使同源材料始终遵守同一分区。2.4B 的人工金标准配置以 32,000 条为基准：12,000 条训练，4,000 条开发，4,000 条校准，4,000 条阈值选择，8,000 条最终测试。

第二步：建立基础语言能力

基础阶段从随机初始化出发，以 next-token prediction 学习语言结构和上下文关系。训练配方以 50B 输入 tokens 配置基础阶段，并使用 65,536 词表统一编码。词表构建与训练语料遵守相同的验收排除边界。

第三步：进行金融混合适配

金融适配采用 5B 输入 tokens 的混合配方：4B 金融原文、0.75B 通用材料、0.20B 阅读问答、0.05B 立场与事件任务。金融材料提供专业表达，通用材料维持语言覆盖，问答与任务监督建立证据和输出之间的联系。各流分别管理抽样、有效监督位置与损失权重。

第四步：任务训练、校准与交付

目标条件化 SFT 将金融语义许可接入监督，分别学习投资立场与指标方向。随后依次完成开发选模、概率校准、接受规则选择与最终测试。交付对象绑定模型、词表、任务协议、校准参数和版本信息，让每一次判断都对应一套明确的系统配置。

闭环从原始材料开始，经过标准定义、语言学习、金融适配与任务训练，最终连接到结构化判断和人工复核；使用反馈进入下一轮训练数据整理，并由新的独立样本检验更新效果。

特色一：金融语义许可监督

金融材料经常同时包含事实变化、作者态度和投资行动。把这些信息混成一个“正面 / 负面”标签，很容易让模型抓住情绪词，却回答错真正的问题。

例如：**“A 公司营收同比增长，但我仍然减持 A。”** 这里的指标方向是向上，作者表达的投资立场可以是看空；如果减持来自仓位或对冲约束，还需要结合任务规定的上下文解释。

我围绕这种关系设计逐轴监督协议：每次编辑都单独判断，它影响了哪个目标、哪个持有人和哪条任务轴。对于有明确监督的变化，重新标注；对于语义保持的部分，保留原标签；关系无法确定时，不强加跨样本约束。

标签保持与概率保持分别处理

同义改写可以要求输出分布接近。新增一条同方向证据，虽然类别可能保持，置信度却可以合理提高。因此，系统分别记录“保持标签”和“保持分布”的许可，使一致性约束服从语义，而非机械追求所有输出相同。

训练以两端的正确标签为锚点：严格等价的编辑使用分布一致性约束；有效改变的编辑使用相对响应约束，要求模型向新的正确方向移动。审核标签、编辑名称和许可记录只控制监督，不进入模型 prompt 暗示答案。

将金融判断拆成可以解释的关系

这项设计的贡献，是把目标、持有人、条件和证据范围连接到具体的编辑规则与损失计算。它让模型的行为要求具体化：无关措辞变化时保持判断，有效语义变化时正确响应，引用或目标切换时重新识别归属。

同一主干通过任务前缀区分立场与事件方向，保留共享语言能力。语义协议负责规定两条任务如何相互帮助，以及哪些信息不能被混用。

特色二：保持训练目标的扩容工程

模型变大后，最容易被忽略的问题是：代码仍然可以运行，loss 仍然下降，实际学习目标却已经发生变化。我将数据计量与运行时优化放进同一套训练契约，明确规定每项计算应该保留什么。

在数据层，明确谁获得多少学习权重

原文有大量 next-token 监督，问答主要监督答案，一条立场记录通常只有一个标签。同一原文生成二十个编辑，也不会自然变成二十个独立事件。

训练目标分别计量自然样本、样本家族、任务视图与有效监督位置。审核视图先在家族内汇总，再按任务聚合；自然样本保持自己的分布。数据流出现频率、任务权重和重复曝光分别记录，使实际优化目标可以从训练账本还原。

多卡与梯度累积采用整次更新的有效分母。对于默认平均梯度的 W 个 rank，每个 rank 使用 W × λ × 本地损失和 / 全局有效分母，仅计算全局有效分母大于零的任务，缺席任务跳过。这样，同一有效 batch 的学习目标不会因为被切成不同微批或分到不同设备而无意改变。

在计算层，保留监督和信息边界

单标签任务先选取答案位置的 hidden，再计算完整词表投影与交叉熵。上下文仍完整通过主干；省去的是没有直接监督的输出投影。以 batch=2、长度=2,048、词表=65,536 的 FP32 输出为例，全序列 logits 张量为 1 GiB，选取两个监督位置后为 0.5 MiB。这是可以直接按张量形状核算的资源差异。

样本打包采用分段因果 attention，确保一个样本不能读取相邻样本的答案。共享 embedding 与输出头保持同一个参数对象；分片与恢复同时管理优化器、随机状态和数据消费位置。

这套工程以有效位置输出、分项损失、梯度和参数更新作为逐级验收对象，将资源优化与实验含义连接起来。数据定义什么值得学习，运行时负责准确执行这一目标。

真正的工程挑战，来自定义之间的冲突

让模型、标注者和使用者回答同一个问题

标题与全文、作者观点与本人判断、经营事实与投资立场，都可能给出不同的合理答案。项目把这些区别放进任务字段和标注规则，使错误能够定位到具体目标、角色或证据范围。个人判断还要带上当时的信息、期限与约束，才能解释观点为何发生变化。

这项取舍增加了数据整理的精度，也让后续训练拥有更稳定的监督对象。模型学习的每个标签，都对应明确的问题和可使用的信息。

让新增训练投入对应真正的能力改善

Trial 的类别失效说明，更多正确答案不一定意味着关键能力改善。项目同时记录独立样本、重复曝光、监督位置和更新次数，将采样变化与计算预算联系起来。语义约束的效果也要与使用同一批编辑、只做普通交叉熵的配置比较，才能分清数据贡献和损失设计的贡献。

从 24M 到 2.4B，这个问题进一步扩展到多流和多卡。统一分母与样本家族计量，让训练配方拥有可以检查的数学含义，也让每次修改都有清楚的归因路径。

在规模优化中保持同一个训练问题

按 FP32 参数、梯度及两份 Adam 状态计算，2.4B 的主要训练状态约为 38.36 GB，尚未包含激活与临时张量。精度、分片、重计算和打包因此都需要进入运行时设计。

每项优化都沿同一条边界展开：改变执行方式，保持监督目标、样本可见范围与状态语义。投影位置可以改变，完整词表损失需要保留；样本可以打包，attention 必须隔离；设备可以变化，实际梯度权重必须一致。这是整个扩容工程的技术核心。

一条面向个人金融研究的专用模型路线

同量级金融模型已经形成不同的技术方向：Eva-4B 面向财报电话会的回答质量分类，FinanceParam 2.9B 围绕金融知识与人群情境组织监督，FinLCR-4B 聚焦长文财务推理。[1][2][3]

130U-FinLLM 的重心是**个人金融标准的内化，以及目标、持有人和证据之间的关系建模。**它把金融语义许可与训练目标计量连接起来，形成贯穿材料、监督、计算和使用的专用系统。

MCP、Tools、Skills 和 ASR 在这个系统中各有位置：连接资料、获取数据、执行计算、管理工作流与转录语音。专用模型负责反复出现的金融判读任务；工具和检索负责提供可更新的信息。两者共同服务个人研究流程。

24M Trial 是项目对外展示的方法窗口，2.4B 是面向自用的模型版本。从最初的数据和类别问题，到语义监督、多任务计量和运行时扩容，这条路径体现的是完整的训练工程能力：**能够定义问题、组织数据、设计监督、控制计算，并将模型输出接入自己的金融研究。**

技术参考

项目的组合设计建立在成熟语言模型与训练方法之上。反事实行为测试和有效监督位置投影的相关工作，为语义协议与运行时设计提供了技术基础。[4][5] 主干实现的第三方来源在公开 Trial 仓库中保留。

1. Eva-4B：金融回答质量分类
2. FinanceParam：2.9B 金融适配模型
3. FinLCR：金融长上下文推理
4. ARTS：目标相关的行为鲁棒性测试
5. Cut Your Losses：有效监督位置与输出计算

130U / TRAINING SYSTEM / PRIVATE MODEL

从个人语料到金融判断

2.4B 自用金融语言模型 · 从数据到判断的完整训练体系

2.4B

130U / FINANCIAL LLM

---

01 / DATA CONTRACT

SOURCES

两类个人材料 + 基础语料

本人原创历史观点 / 本人审核公开文本
通用语言语料 / 金融原文
保留作者、标注者和真实可得时间

PROTOCOL

定义判断对象与证据范围

task / target / holder / scope
原文立场、事件方向、个人判断分开
来源、事件与派生记录归入 family

PARTITION

先分区，再生成训练视图

32k gold 配额：12k train + 20k 验收
教师监督与审核编辑仅进入训练区
同一 family 及其全部视图保持同区

验收原文从自建语料、词表及训练流中排除

02 / TRAINING RAIL

各阶段独立取数；A → B → C 的箭头表示权重传递

A / BASE PRETRAINING

基础语言训练

50B tokens 配方 / 65,536 词表
随机初始化：28 层、hidden 2,560
Q20 / KV4 · SwiGLU · tied embedding

B / MIXED ADAPTATION

金融混合适配

4.0B 金融 + 0.75B 通用保持
0.20B 阅读 QA + 0.05B 立场 / 事件
各流 loss mask、抽样与权重分别管理

C / TASK TRAINING

目标条件化 SFT

目标 / 持有人 / 证据范围条件化
立场与指标方向采用不同任务前缀
逐轴语义许可接入监督与配对约束

开发用于调参 · 校准、阈值与测试材料不进入训练

03 / INDEPENDENT ACCEPTANCE

4k DEV

开发选模

挑选 checkpoint
等预算比较 / 错误归因

4k CALIBRATION

概率校准

按任务拟合 T
保留三类条件概率

4k THRESHOLD

接受规则

冻结接受 / 复核策略
记录风险与覆盖率

8k FINAL TEST

最终测试

8k 自然 + 另 3k 同族探针
派生探针不增加独立样本

RELEASE

版本化交付

模型 + 词表 + 规则
校准、版本与证据绑定

TRIAL → 2.4B

复用任务协议、来源链与恢复语义；重做词表、权重、运行时与校准。

24M Trial 公开展示训练过程与工程实践；2.4B 版本面向个人金融研究使用。

同一训练目标，贯穿数据与运行时

语义许可监督 × 样本家族计量 × 保持目标的运行时

28 L

130U / FINANCIAL LLM

01 / INPUTS & ISOLATION

实线：计算结果　虚线：监督与边界控制

MODEL INPUT

按数据流构造输入

raw：原文；QA：问答 prompt
S/E：目标 / 持有人 / 证据范围
个人判断输入隔离待预测结论

AUDIT SIDE CHANNEL

监督与边界控制

gold / family / stream / pair IDs
loss mask / pair gate / weights
segment IDs 控制 attention
审核标签不写入模型 prompt

SHARED DECODER / 28 LAYERS

Transformer block × 28

H [B, S, 2560]

分段因果 attention / position IDs

segments

mask / answer indices

VALID POSITIONS

先选择有效监督位置

H_valid [M, 2560]
单标签：每任务视图 1 个位置
QA / LM：保留各自全部有效位置

FULL VOCABULARY

共享权重投影 + 精确 CE

logits [M, 65536]
完整词表归一化，保持原监督目标
可分块 / 融合；不改成仅三标签 CE
gold IDs ← 监督旁路

S/E: q = softmax(label logits)

02 / LOSS & OPTIMIZATION

PERMITTED PAIRS

受控约束：按许可生效

三标签分布 + 两端索引 + 逐轴许可
有效 pair 进入约束；同源内计量
正确标签锚定两端的监督目标

GLOBAL OBJECTIVE

各项分母，分别全局聚合

raw / QA：各自声明的监督单位
S/E 与 pair：族内平均后聚合
family / stream / λ ← 监督旁路

OPTIMIZER STEP

反向传播与参数更新

各流 CE + 许可约束完成归一化
更新、跳步与曝光分别计数
精度 / 分片 / 恢复共用验收基准

一次 optimizer 尝试；成功更新另计

EQUIVALENCE FIRST　同 batch 对照 logits / loss / gradients / optimizer delta，再比较显存与吞吐。

从数据语义到参数更新：每项性能优化都保持监督目标、样本边界与状态语义。